

MÓDULO 2: MÉTODOS ESTADÍSTICOS PARA IA

OBJETIVO GENERAL: INTRODUCIR LOS FUNDAMENTOS ESTADÍSTICOS NECESARIOS PARA ANALIZAR DATOS Y EVALUAR MODELOS DE INTELIGENCIA ARTIFICIAL, FAVORECIENDO LA TOMA DE DECISIONES BASADAS EN EVIDENCIA.

- CLASE 1: NOCIONES DE PROBABILIDAD. ESTADÍSTICA DESCRIPTIVA.
- CLASE 2: TEST DE HIPÓTESIS.
- CLASE 3: REGRESIÓN.
- CLASE 4: ESTADÍSTICA NO PARAMÉTRICA.

MÓDULO 2: MÉTODOS ESTADÍSTICOS PARA IA

OBJETIVO GENERAL: INTRODUCIR LOS FUNDAMENTOS ESTADÍSTICOS NECESARIOS PARA ANALIZAR DATOS Y EVALUAR MODELOS DE INTELIGENCIA ARTIFICIAL, FAVORECIENDO LA TOMA DE DECISIONES BASADAS EN EVIDENCIA.

- CLASE 1: NOCIONES DE PROBABILIDAD. ESTADÍSTICA DESCRIPTIVA.
- CLASE 2: TEST DE HIPÓTESIS.
- CLASE 3: REGRESIÓN.
- CLASE 4: ESTADÍSTICA NO PARAMÉTRICA.

Clase 3 - Parte 3: Métodos Estadísticos para IA

Regresión Lineal Múltiple



Objetivos de esta presentación

- ▶ Extender el modelo lineal simple a más de una variable explicativa.
- ▶ Interpretar los coeficientes en un modelo múltiple.
- ▶ Evaluar la significancia global y parcial de las variables.
- ▶ Realizar un test de hipótesis sobre un modelo lineal múltiple
- ▶ Aplicar el modelo en Python y analizar resultados.

Resumen

Modelo de regresión lineal múltiple

Estimación de mínimos cuadrados: forma matricial

Evaluación de modelos

Resumen

Modelo de regresión lineal múltiple

Estimación de mínimos cuadrados: forma matricial

Evaluación de modelos

Modelo de regresión lineal múltiple

- ▶ En muchas ocasiones, una variable y depende de más de una variable, digamos $x_1, x_2, x_3, \dots, x_k$.
- ▶ Cuando una sola variable no explica bien la variabilidad, se debe incorporar más información.
- ▶ Algunos ejemplos:
- ▶ Predecir el precio de una vivienda (y) que, en principio, puede ser una función de muchas cosas (**ejemplo 22**). Podríamos estar interesados en evaluar su relación con: la superficie total (x_1), la cantidad de habitaciones (x_2) y la ubicación (x_3). En ese caso, se piensa que esas variables explican la variable dependiente y , se les dice **variables explicativas** (independientes)¹.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

¹En el ejemplo 22, otra variable independiente es la antigüedad de la vivienda.

Modelo de regresión lineal múltiple

- Otra situación que puede ocurrir, es cuando hay una relación no lineal. En algunos casos es linealizable, tomemos un ejemplo sencillo, pensemos en la posición de un móvil lanzado verticalmente con una velocidad inicial v_0 desde una altura h , se cumple: $y = h + v_0 t - \frac{1}{2} g t^2$ (aquí t es el tiempo y g la aceleración de la gravedad). Si llamamos $x_1 = t$ y $x_2 = t^2$; y $\beta_0 = h$, $\beta_1 = v_0$, $\beta_2 = -\frac{1}{2} g$ entonces queda un modelo:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

Modelo de regresión lineal múltiple

- ▶ En definitiva, pensamos en un modelo del tipo:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + E \quad (1)$$

- ▶ Aquí nuevamente consideramos que las variables independientes (explicativas) x_i son determinísticas.
- ▶ A los parámetros β_i se los denomina **coeficientes de regresión**. Cada β_i representa el cambio esperado en y manteniendo las demás variables constantes. Permite distinguir el efecto individual vs. el efecto conjunto.
- ▶ Lo probabilístico lo pone E , que es un error similar al propuesto en la Ec. (1) de la presentación 3.1. Su esperanza es $E\{E\} = 0$. Por lo tanto:

$$E\{Y\} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k \quad (2)$$

Suposiciones del modelo de regresión lineal múltiple

- ❖ Linealidad
- ❖ Independencia de los errores
- ❖ Homocedasticidad
- ❖ Normalidad de los errores
- ❖ No colinealidad entre las x_i

Suposiciones del modelo de regresión lineal múltiple

❖ Linealidad

- ▶ Se asume que la relación entre cada variable independiente x_i y la variable dependiente y es lineal en los parámetros.
- ▶ Esto no implica necesariamente que las variables sean numéricamente lineales, sino que el modelo puede escribirse como una combinación lineal de coeficientes:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + E$$

- ▶ Puede verificarse mediante gráficos de residuos vs. valores ajustados (deben verse aleatorios).

Suposiciones del modelo de regresión lineal múltiple

❖ Independencia de los errores

- ▶ Los errores (e_i) deben ser independientes entre sí.
- ▶ Esto significa que el valor del error en una observación no depende del error en otra.
- ▶ Puede verificarse mediante test de Durbin–Watson* (valores cercanos a 2 indican independencia).

*<https://www.investopedia.com/terms/d/durbin-watson-statistic.asp>

Suposiciones del modelo de regresión lineal múltiple

❖ Homocedasticidad (varianza constante de los errores)

- ▶ Se asume que los errores tienen igual varianza en todos los niveles de las variables explicativas ($V(e_i) = \sigma^2$).
- ▶ Puede verificarse mediante gráfico de residuos vs. ajustados (no debe observarse forma de embudo).
- ▶ Se puede corregir aplicando transformaciones (por ejemplo $\log(Y)$).

Suposiciones del modelo de regresión lineal múltiple

❖ Normalidad de los errores

- ▶ Los errores deben seguir una distribución Normal con media 0 y varianza constante.
- ▶ Puede verificarse mediante QQ-plot o test de Shapiro–Wilk**.
- ▶ Se puede corregir aplicando test no paramétricos.

**https://es.wikipedia.org/wiki/Prueba_de_Shapiro-Wilk

Suposiciones del modelo de regresión lineal múltiple

❖ No colinealidad entre las x_i

- ▶ Las variables explicativas no deben estar fuertemente correlacionadas entre sí.
- ▶ Una alta correlación lineal entre predictores hace que sea difícil separar sus efectos individuales sobre Y .
- ▶ Puede verificarse mediante el cálculo del **Factor de Inflación de la Varianza (VIF: Variance Inflation Factor)**, donde los valores > 5 (o 10) indican problemas, los coeficientes estimados pueden volverse inestables y sus errores estándar inflarse.
- ▶ Se puede corregir eliminando o combinando variables correlacionadas, o aplicar métodos de regularización (Ridge, Lasso).

Estimación de mínimos cuadrados

En lo que sigue generalizaremos lo que vimos en la Presentación 3.1 para un sistema de k variables independientes.

Denotemos la i -ésima observación de x_j como x_{ij} , entonces si tomamos n mediciones tendremos datos del tipo:

$$(x_{i1}, x_{i2}, \dots, x_{ik}, y_i) \text{ para } i = 1, \dots, n \quad (3)$$

Desarrollemos el caso $k = 2$.

A la Ec. (1) la podemos escribir de forma reducida de la siguiente manera:

$$y_i = \beta_0 + \sum_{j=1}^2 \beta_j x_{ij} + e_i \text{ para } i = 1, \dots, n \quad (4)$$

donde e_i es una salida de la variable aleatoria E . Podemos entonces, escribir la **función de mínimos cuadrados**:

$$L = \sum_{i=1}^n \left[y_i - \left(\beta_0 + \sum_{j=1}^2 \beta_j x_{ij} \right) \right]^2 \quad (5)$$

Estimación de mínimos cuadrados

Definida la Ec. (5), lo que resta hacer es minimizarla respecto de los coeficientes de regresión:

$$\left. \frac{\partial L}{\partial \beta_0} \right|_{\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2} = -2 \sum_{i=1}^n \left[y_i - \left(\hat{\beta}_0 + \sum_{j=1}^2 \hat{\beta}_j x_{ij} \right) \right] = 0$$

$$\left. \frac{\partial L}{\partial \beta_j} \right|_{\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2} = -2 \sum_{i=1}^n x_{ij} \left[y_i - \left(\hat{\beta}_0 + \sum_{j=1}^2 \hat{\beta}_j x_{ij} \right) \right] = 0$$

Arreglando estas ecuaciones llegamos a las denominadas **Ecuaciones Normales:**

$$\begin{aligned} n\hat{\beta}_0 + \sum_{i=1}^n \hat{\beta}_1 x_{i1} + \sum_{i=1}^n \hat{\beta}_2 x_{i2} &= \sum_{i=1}^n y_i \\ \sum_{i=1}^n \hat{\beta}_0 x_{i1} + \sum_{i=1}^n \hat{\beta}_1 x_{i1}^2 + \sum_{i=1}^n \hat{\beta}_2 x_{i1} x_{i2} &= \sum_{i=1}^n x_{i1} y_i \\ \sum_{i=1}^n \hat{\beta}_0 x_{i2} + \sum_{i=1}^n \hat{\beta}_1 x_{i1} x_{i2} + \sum_{i=1}^n \hat{\beta}_2 x_{i2}^2 &= \sum_{i=1}^n x_{i2} y_i \end{aligned} \quad (6)$$

Resolviendo este sistema obtenemos la estimación de mínimos cuadrados.

Resumen

Modelo de regresión lineal múltiple

Estimación de mínimos cuadrados: forma matricial

Evaluación de modelos

Estimación de mínimos cuadrados: forma matricial

Es conveniente para este tipo de problemas expresar las ecuaciones en forma matricial. Entonces, continuando con $k = 2$ y ahora supongamos que tomamos muestras de tamaño $n = 4$ entonces según la Ec. (4) tenemos:

$$\begin{aligned}y_1 &= \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + e_1 \\y_2 &= \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + e_2 \\y_3 &= \beta_0 + \beta_1 x_{31} + \beta_2 x_{32} + e_3 \\y_4 &= \beta_0 + \beta_1 x_{41} + \beta_2 x_{42} + e_4\end{aligned}$$

reescribiendo de manera matricial queda:

$$\underbrace{\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}}_{n \times 1} = \underbrace{\begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ 1 & x_{31} & x_{32} \\ 1 & x_{41} & x_{42} \end{bmatrix}}_{n \times (k+1)} \underbrace{\begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}}_{(k+1) \times 1} + \underbrace{\begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \end{bmatrix}}_{n \times 1} \Rightarrow \mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}. \quad (7)$$

Estimación de mínimos cuadrados: Matricial

Para operar con la Ec. (7) debemos conocer algunas operaciones matriciales². Para obtener la ecuación equivalente a la Ec. (5) notemos que la suma de los residuos la obtenemos con la siguiente operación:

$$\mathbf{e}^T \mathbf{e} = \begin{bmatrix} e_1 & e_2 & e_3 & e_4 \end{bmatrix} \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \end{bmatrix} = e_1^2 + e_2^2 + e_3^2 + e_4^2, \quad (8)$$

donde la operación T es la matriz transpuesta. Entonces la función de mínimos cuadrados es:

$$L = \underbrace{(\mathbf{y} - \mathbf{X}\beta)^T}_{\mathbf{e}^T} \underbrace{(\mathbf{y} - \mathbf{X}\beta)}_{\mathbf{e}}, \quad (9)$$

derivando esta ecuación respecto de β se obtiene la forma matricial de la **Ecuación Normal**:

$$\mathbf{X}^T \mathbf{X} \hat{\beta} = \mathbf{X}^T \mathbf{y}, \quad (10)$$

²Para una revisión puede consultar en:

https://www.mate.unlp.edu.ar/practicas/49_10_29052020002917.pdf

Estimación de mínimos cuadrados: Matricial

Detengámonos un poco en la Ec. (10).

- Aquí la repetimos para indicar las dimensiones de las matrices:

$$\underbrace{\mathbf{X}^T \mathbf{X}}_{(k+1) \times (k+1)} \hat{\beta} = \underbrace{\mathbf{X}^T}_{(k+1) \times n} \mathbf{y} \quad (11)$$

por lo tanto, dimensionalmente es correcta.

- Para recordar este resultado es útil pensarlo de la siguiente forma. Supongamos que estudiamos un modelo determinístico del tipo lineal $\mathbf{y} = \mathbf{X}\hat{\beta}$, entonces para “despejar” $\hat{\beta}$ podría realizar la siguiente cuenta. Primero multiplico a izquierda³ por \mathbf{X}^T

$$\mathbf{X}^T \mathbf{y} = \mathbf{X}^T \mathbf{X} \hat{\beta}$$

luego, como ahora $\mathbf{X}^T \mathbf{X}$ es una matriz cuadrada, puedo calcular su inversa, y multiplicar a izquierda nuevamente:

$$(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X} \hat{\beta} = \hat{\beta} \quad (12)$$

³Multiplicar a izquierda o derecha en matrices es diferente al caso de escalares.

Resumen

Modelo de regresión lineal múltiple

Estimación de mínimos cuadrados: forma matricial

Evaluación de modelos

Evaluación del modelo de regresión lineal múltiple

1. Coeficiente de determinación R^2

- ▶ Representa la **proporción de la variabilidad de la variable dependiente** y que puede explicarse a partir de las variables independientes incluidas en el modelo.

- ▶ Se calcula como:
$$R^2 = 1 - \frac{SS_E}{SS_T}$$

donde SS_E es la suma de los cuadrados de los errores y SS_T es la suma total de los cuadrados respecto a la media.

- ▶ Su valor varía entre 0 y 1:
 - $R^2 = 1 \rightarrow$ el modelo explica perfectamente la variabilidad observada.
 - $R^2 = 0 \rightarrow$ el modelo no explica nada más allá de la media.

Cuidado!! Agregar variables siempre aumenta R^2 , aunque no necesariamente sean relevantes.

Evaluación del modelo de regresión lineal múltiple

2. Coeficiente de determinación $R^2_{ajustado}$

► Penaliza la inclusión de variables innecesarias.

► Se calcula como:
$$R^2_{ajustado} = 1 - \frac{(1-R^2)(n-1)}{n-p-1}$$

donde n es el número de observaciones y p el número de predictores.

► Tiene como ventaja que solo aumenta cuando una nueva variable mejora el modelo más de lo esperado por azar.

► En regresión lineal múltiple se prefiere su uso por sobre R^2 para comparar modelos con diferente cantidad de variables.

Evaluación del modelo de regresión lineal múltiple

3. Test F global

- ▶ ¿El modelo explica significativamente a y ?
- ▶ El Test F global evalúa si **el modelo en su conjunto** tiene capacidad explicativa significativa.

- ▶ Hipótesis:

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

$$H_1: \text{Al menos una } \beta_i \neq 0$$

- ▶ Si el **p-valor asociado al test F** es menor que el nivel de significancia (por ejemplo, 0.05), se **rechaza** H_0 ,concluyendo que el modelo tiene poder explicativo.

La **distribución F** es también conocida como de Fisher-Snedecor)

Evaluación del modelo de regresión lineal múltiple

4. Métricas adicionales de error

- ▶ Aunque el modelo sea estadístico, es útil cuantificar el error de predicción:
- ▶ **RMSE (Root Mean Squared Error):** mide el error promedio de predicción en las mismas unidades que Y .

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y})^2}$$

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}|$$

- ▶ **MAE (Mean Absolute Error):** más robusto frente a valores atípicos.
- ▶ Estas métricas permiten comparar modelos sobre conjuntos de validación o con nuevas observaciones.
- ▶ En enfoques de IA, estas medidas son las más utilizadas para evaluar desempeño predictivo.

Multicolinealidad

- ▶ Se dice que existe multicolinealidad cuando **dos o más variables explicativas están fuertemente correlacionadas entre sí.**
- ▶ Como consecuencia:
 - **Los coeficientes estimados se pueden volver inestables:** pequeños cambios en los datos pueden alterar significativamente los valores de β_i .
 - **Podemos tener errores estándar inflados:** los coeficientes parecen poco significativos (p-valores altos) aunque las variables sí lo sean.
 - **Difícil interpretación:** se pierde la capacidad de aislar el efecto individual de cada predictor.
- ▶ La multicolinealidad no afecta el poder predictivo global del modelo, pero sí distorsiona la interpretación estadística de los coeficientes.

Multicolinealidad

¿Cómo detectarla?

► **Matriz de correlaciones:** valores altos ($|r| > 0.8$) entre predictores pueden alertar del problema.

► **Factor de Inflación de la Varianza (VIF):**

$$VIF_i = \frac{1}{(1 - R_i^2)}$$

donde R_i^2 es el coeficiente de determinación al estimar la relación entre X_i sobre las demás variables.

- $VIF = 1$: sin correlación.
- $5 < VIF < 10$: posible multicolinealidad.
- $VIF > 10$: multicolinealidad severa.

En Python, puede calcularse fácilmente con `variance_inflation_factor` de la librería `statsmodels`.

Multicolinealidad

¿Cómo mitigar la multicolinealidad?

- ▶ **Eliminar variables redundantes:** si dos variables aportan información similar, mantener solo una.
- ▶ **Combinar variables correlacionadas:** por ejemplo, construir índices o promedios.
- ▶ **Aplicar métodos de regularización:**
 - Ridge Regression (L2):** penaliza los coeficientes grandes, estabilizando la estimación.
 - Lasso Regression (L1):** además de estabilizar, puede eliminar variables irrelevantes.
- ▶ **Recoger más datos:** en algunos casos, una muestra más grande puede reducir la inestabilidad numérica

Regresión Lineal en Python

- ▶ En Python existen dos alternativas principales para ajustar un modelo lineal.
- ▶ La función ***statsmodels.OLS()*** de la librería ***statsmodels***, cuyo propósito es el realizar un ajuste estadístico con interpretación completa.

```
# Ajuste del modelo
modelo = sm.OLS(y, X).fit()

# Resumen completo
print(modelo.summary())
```

OLS (Ordinary Least Squares)



- ▶ La salida del código es:
 - ☐ Coeficientes estimados
 - ☐ Errores estándar
 - ☐ Estadísticos t y p-valores
 - ☐ Intervalos de confianza
 - ☐ R^2 y R^2 ajustado
 - ☐ Test F, Durbin-Watson, Jarque-Bera, etc.

El método OLS busca minimizar la suma de los cuadrados de los residuos (la diferencia entre los valores reales y los predichos).

Regresión Lineal en Python

- ▶ La otra alternativa es usar la función ***LinearRegression()*** de la librería **scikit-learn**, cuyo propósito es tener un enfoque predictivo (entrenamiento, evaluación con R^2 , RMSE, etc.). Es más usado en Machine Learning.

```
# Ajuste del modelo
modelo = LinearRegression()
modelo.fit(X, y)

# Coeficientes
print("Intercepto:", modelo.intercept_)
print("Coeficientes:", dict(zip(X.columns, modelo.coef_)))
```

- ▶ La salida del código es:
 - ☐ Coeficientes estimados
 - ☐ R^2

Ejemplo 22 utilizando la función statsmodels.OLS()

```
# ----- Ajuste con statsmodels (OLS) -----
X = data[["superficie", "habitaciones", "antiguedad"]]
X = sm.add_constant(X) # agrega intercepto
y = data["precio"]

# Ajuste del modelo
modelo = sm.OLS(y, X).fit()

# Resumen completo
print(modelo.summary())
```

OLS Regression Results

Dep. Variable:	precio	R-squared:	0.876
Model:	OLS	Adj. R-squared:	0.873
Method:	Least Squares	F-statistic:	274.2
Date:	Sun, 12 Oct 2025	Prob (F-statistic):	1.74e-52
Time:	16:43:44	Log-Likelihood:	-1397.5
No. Observations:	120	AIC:	2803.
Df Residuals:	116	BIC:	2814.
Df Model:	3		
Covariance Type:	nonrobust		

Ejemplo 22 utilizando la función statsmodels.OLS()

```
# ----- Ajuste con statsmodels (OLS) -----
X = data[["superficie", "habitaciones", "antiguedad"]]
X = sm.add_constant(X) # agrega intercepto
y = data["precio"]

# Ajuste del modelo
modelo = sm.OLS(y, X).fit()

# Resumen completo
print(modelo.summary())
```

```
=====
```

	coef	std err	t	P> t	[0.025	0.975]
const	6.041e+04	9552.992	6.324	0.000	4.15e+04	7.93e+04
superficie	1312.7647	50.679	25.903	0.000	1212.388	1413.142
habitaciones	1.649e+04	1872.172	8.808	0.000	1.28e+04	2.02e+04
antiguedad	-863.3354	227.469	-3.795	0.000	-1313.867	-412.804

```
=====
```

Omnibus:	0.382	Durbin-Watson:	1.839
Prob(Omnibus):	0.826	Jarque-Bera (JB):	0.212
Skew:	-0.101	Prob(JB):	0.900
Kurtosis:	3.042	Cond. No.	523.

```
=====
```

Conclusiones

De la regresión lineal simple a la múltiple

- ▶ En esta unidad aprendimos a modelar relaciones lineales entre variables, pasando de un único predictor (x) a varios (x_1, x_2, \dots, x_k) .
- ▶ La regresión lineal simple nos permitió comprender la idea de pendiente, ordenada al origen y el concepto de “mejor ajuste” mediante mínimos cuadrados.
- ▶ La regresión lineal múltiple extendió este razonamiento a más dimensiones, permitiendo analizar efectos combinados y cuantificar la contribución de cada variable.
- ▶ Este paso constituye la base conceptual de muchos modelos más complejos en ciencia de datos y aprendizaje automático.

Conclusiones

Limitaciones del modelo lineal

- ▶ El modelo lineal múltiple es poderoso, pero se apoya en supuestos fuertes (linealidad, normalidad, independencia).
- ▶ En muchos fenómenos reales, las relaciones pueden ser no lineales.
- ▶ En esos casos, el modelo lineal puede servir como punto de partida o referencia, pero no captará toda la complejidad del sistema.
- ▶ Esta limitación abre el camino hacia:
 - Modelos polinomiales o transformaciones no lineales.
 - Métodos de aprendizaje automático más flexibles (árboles, redes neuronales, boosting, etc.).

Conclusiones

De la Estadística a la Inteligencia Artificial

- ▶ Desde la perspectiva estadística, la regresión busca explicar y cuantificar relaciones entre variables (inferencia).
- ▶ Desde la perspectiva de IA / Machine Learning, busca predecir y generalizar el comportamiento futuro (predicción).
- ▶ Aunque el objetivo cambia, ambos enfoques comparten los mismos fundamentos: los conceptos de ajuste, error, validación y generalización.
- ▶ Esta unidad nos permitió puentear ambos mundos, preparando el terreno para el estudio de modelos más avanzados de aprendizaje supervisado.

Regresión lineal: ¿Estadística o Inteligencia Artificial?

- ▶ Misma ecuación, distinto propósito:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

- ▶ La **regresión lineal** en **estadística**, se la entiende como una **herramienta inferencial**: busca **explicar** y **cuantificar** la relación entre variables.
- ▶ En **IA** o **aprendizaje automático**, se la usa como un **modelo predictivo**: busca **minimizar el error de predicción** y **generalizar** a nuevos datos. Es uno de los modelos más antiguos y también uno de los más usados.

Regresión lineal desde la Estadística

¿Existe evidencia estadística de una relación lineal entre las variables?

- ▶ Se parte de un **modelo probabilístico**: los errores ε se asumen independientes y distribuidos normalmente.
- ▶ Otros supuestos: normalidad, homocedasticidad, independencia
- ▶ El objetivo es **inferir los parámetros** β_0, β_1 y **evaluar hipótesis** sobre ellos.
- ▶ Conceptos clave: Intervalos de confianza, Test de hipótesis, p-valor

Regresión lineal como modelo de Machine Learning

¿Qué tan bien puede el modelo predecir valores futuros?

- ▶ Se considera un **algoritmo supervisado** que aprende una función $f(x)$ que minimiza una **función de pérdida** (por ejemplo, el error cuadrático medio).
- ▶ No se requiere asumir distribución normal ni independencia estricta de los errores.
- ▶ Interesa la **capacidad predictiva** más que la inferencia.
- ▶ Conceptos clave: Entrenamiento y validación, Regularización, Métricas de desempeño.